



CORHUILA

CORPORACIÓN UNIVERSITARIA DEL HUILA
Vigilada Mineducación

INSTITUCIÓN DE EDUCACIÓN SUPERIOR SUJETA A INSPECCIÓN
Y VIGILANCIA POR EL MINISTERIO DE EDUCACIÓN NACIONAL - SNIES 2828

1.

Actividad Práctica – Semana 2

Clasificación de Datos y las V del Big Data

Cristhian Gaitán Guzmán

Facultad de Ingeniería, Corporación Universitaria del Huila (CORHUILA)

Ciencia de Datos (Cód. 69109) [Pénsum 40D, Grupo 1]

Jesús Ariel Gonzáles Bonilla

Agosto de 2026

📍 Sede Quirinal: Calle 21 No. 6 - 01
📍 Sede Prado Alto: Calle 8 No. 32 - 49 PBX: (608) 8754220
📍 Sede Pitalito: Carrera 2 No. 1 - 27 - PBX: (608) 8360699
✉ Email: contacto@corhuila.edu.co - www.corhuila.edu.co
Personería Jurídica Res. Ministerio de Educación No. 21000 de Diciembre 22 de 1989
NIT. 800.107.584-2



CORPORACIÓN UNIVERSITARIA DEL HUILA - CORHUILA
"Diseño y prestación de servicios de docencia, investigación y extensión de programas de pregrado, aplicando todos los requisitos de las normas ISO implementadas en sus sedes Neiva y Pitalito"



1. Fuentes de datos y clasificación

Para dar continuidad al caso de Siemens y su problema de mantenimiento predictivo de motores y equipos industriales, se identifican a continuación ocho fuentes de datos concretas, clasificadas según su nivel de estructura. Esta clasificación retoma y detalla el inventario de datos planteado en la semana anterior, separando explícitamente cada fuente en estructurada, semiestructurada o no estructurada.

#	Fuente de datos	Descripción	Tipo de dato
1	Sensores IoT de temperatura	Temperatura registrada durante el funcionamiento del motor.	Estructurado
2	Sensores IoT de vibración	Nivel de vibración producido por el equipo en operación.	Estructurado
3	Sensores de consumo eléctrico	Corriente y energía consumida por el motor durante su uso.	Estructurado
4	Sistema ERP/CMMS — historial de fallas	Registro de fallas ocurridas anteriormente en cada equipo.	Estructurado
5	Sistema ERP/CMMS — registros de mantenimiento	Fechas, tipos y actividades realizadas en cada mantenimiento.	Estructurado



6	Plataforma de monitoreo (Siemens Insights Hub)	Series de tiempo y alertas generadas continuamente por los sensores conectados.	Semiestructurado
7	Registros de eventos del sistema	Logs y alertas generados por las plataformas de monitoreo industrial.	Semiestructurado
8	Informes técnicos de mantenimiento	Documentos redactados por técnicos después de una intervención.	No estructurado

La mayoría de las fuentes son estructuradas porque provienen de sensores numéricos y de campos definidos en el sistema ERP/CMMS. La plataforma de monitoreo y los registros de eventos se consideran semiestructurados porque, aunque tienen una organización parcial (series de tiempo, etiquetas, marcas de tiempo), no siguen un esquema rígido de tabla. Los informes técnicos, al estar escritos en lenguaje natural por los técnicos, son datos no estructurados.

2. Las V del Big Data críticas para el proyecto

De las cinco V del Big Data (volumen, velocidad, variedad, veracidad y valor), todas están presentes en este caso en distintos grados, pero no todas son igual de críticas para la viabilidad del proyecto. La siguiente tabla resume la justificación de cada una.



V	Criticidad	Justificación en el proyecto
Volumen	Alta	Múltiples motores y líneas de producción generan mediciones de temperatura, vibración, corriente y presión de forma constante, lo que acumula grandes cantidades de datos por equipo y por día.
Velocidad	Alta	Los sensores IoT transmiten lecturas en tiempo real o con alta frecuencia, por lo que el sistema debe poder recibir y procesar los datos casi al mismo ritmo en que se generan.
Variedad	Alta	Se combinan datos numéricos estructurados (sensores), datos semiestructurados (logs y eventos de la plataforma de monitoreo) y datos no estructurados (informes técnicos en texto libre).
Veracidad	Crítica	Sensores descalibrados, fallas de conexión o valores faltantes pueden introducir mediciones erróneas que afecten directamente la confiabilidad de cualquier predicción de falla.
Valor	Alta	El análisis solo se justifica si permite reducir fallas inesperadas, tiempos de inactividad y costos de reparación; sin una decisión útil de mantenimiento, los datos no aportan valor real.

Volumen, velocidad y variedad son características casi inevitables en este escenario, dado que se trata de sensores IoT operando de forma continua sobre múltiples equipos. Sin embargo, la V más crítica para el éxito del proyecto es la veracidad: si los datos que alimentan el modelo predictivo

no son confiables, ninguna cantidad de volumen o velocidad va a producir predicciones útiles. Por esta razón, el reto de calidad se desarrolla con mayor detalle en la siguiente sección.

3. Reto de veracidad y forma de detectarlo

3.1 Problema de veracidad identificado

Un problema concreto de veracidad en este proyecto es la posibilidad de que un sensor de vibración o de temperatura se descalibre con el tiempo, o que pierda conexión intermitentemente, generando lecturas erróneas: valores extremos que no corresponden a la realidad física del equipo (por ejemplo, una temperatura de 0°C en un motor en funcionamiento), o vacíos de datos durante ciertos periodos mientras el sensor está desconectado. Si estos datos se usan directamente para entrenar el modelo predictivo o para generar alertas, el sistema podría anticipar fallas que no existen (falsos positivos) o, peor aún, no detectar una falla real porque las lecturas defectuosas ocultaron la tendencia anómala (falsos negativos).

3.2 Cómo se detectaría

- **Rango físico esperado:** comparar cada lectura contra los límites de operación normal del motor (por ejemplo, temperatura o vibración fuera del rango típico del fabricante) y marcar como sospechosos los valores que caen fuera de ese rango.



- **Consistencia temporal:** revisar si una lectura cambia de forma abrupta e improbable entre dos mediciones consecutivas muy cercanas en el tiempo, lo cual suele indicar error de sensor más que un cambio real en el equipo.
- **Vacíos y duplicados:** contar los intervalos de tiempo sin datos (gaps) y los registros duplicados con el mismo timestamp, ya que ambos son señales típicas de fallas de conexión o de transmisión del sensor.
- **Comparación cruzada:** contrastar la lectura de un sensor con variables relacionadas (por ejemplo, temperatura vs. consumo eléctrico); si una sube de forma anómala sin que la otra lo haga cuando históricamente se mueven juntas, se marca la lectura para revisión.

Detectar estos problemas antes del análisis es indispensable, ya que la analítica predictiva del proyecto depende directamente de que los datos de entrada reflejen el estado real de los equipos.

4. Conclusión

Clasificar las fuentes de datos y evaluar las V del Big Data permite entender mejor el terreno sobre el cual se construirá la solución de mantenimiento predictivo para Siemens. Si bien el volumen, la velocidad y la variedad son características casi garantizadas por la naturaleza de los sensores IoT, es la veracidad la que determina si el proyecto realmente puede generar valor: un modelo entrenado con datos poco confiables producirá decisiones de mantenimiento equivocadas, sin importar qué tan sofisticado sea el algoritmo utilizado. Por eso, establecer mecanismos de detección de errores



de sensor desde etapas tempranas del ciclo de vida del proyecto es un paso necesario antes de avanzar hacia el análisis y la visualización de resultados.

5. Referencias

- [1] National Institute of Standards and Technology (NIST), "Data science," Computer Security Resource Center, 2018. [Online]. Available: <https://csrc.nist.gov>
- [2] IBM, "¿Qué es el mantenimiento predictivo?," IBM Think, 2026. [Online]. Available: <https://www.ibm.com/think/topics/predictive-maintenance>
- [3] Siemens AG, "Insights Hub: plataforma de IoT industrial en la nube (anteriormente MindSphere)," Siemens Digital Industries Software, 2026. [Online]. Available: <https://www.siemens.com/en-us/products/insights-hub/>
- [4] IBM, "What is big data?," IBM Think, 2026. [Online]. Available: <https://www.ibm.com/think/topics/big-data>
- [5] IBM, "What is data quality?," IBM Think, 2025. [Online]. Available: <https://www.ibm.com/think/topics/data-quality>
- [6] IBM, "What is a CMMS?," IBM Think, 2025. [Online]. Available: <https://www.ibm.com/think/topics/what-is-a-cmms>