



CORHUILA

CORPORACIÓN UNIVERSITARIA DEL HUILA
Vigilada Mineducación

INSTITUCIÓN DE EDUCACIÓN SUPERIOR SUJETA A INSPECCIÓN
Y VIGILANCIA POR EL MINISTERIO DE EDUCACIÓN NACIONAL - SNIES 2828

1.

Actividad Práctica – Semana 3

Diseña una Arquitectura de Datos

Cristhian Gaitán Guzmán

Facultad de Ingeniería, Corporación Universitaria del Huila (CORHUILA)

Ciencia de Datos (Cód. 69109) [Pénsum 40D, Grupo 1]

Jesús Ariel Gonzáles Bonilla

Agosto de 2026

📍 Sede Quirinal: Calle 21 No. 6 - 01

📍 Sede Prado Alto: Calle 8 No. 32 - 49 PBX: (608) 8754220

📍 Sede Pitalito: Carrera 2 No. 1 - 27 - PBX: (608) 8360699

✉ Email: contacto@corhuila.edu.co - www.corhuila.edu.co

Personería Jurídica Res. Ministerio de Educación No. 21000 de Diciembre 22 de 1989

NIT. 800.107.584-2



CORPORACIÓN UNIVERSITARIA DEL HUILA - CORHUILA

"Diseño y prestación de servicios de docencia, investigación y extensión de programas de pregrado, aplicando todos los requisitos de las normas ISO implementadas en sus sedes Neiva y Pitalito"




1. Introducción

Esta actividad retoma el caso trabajado en las semanas anteriores: el mantenimiento predictivo de motores y equipos industriales en una planta de Siemens. Una vez identificados el problema, los datos necesarios y el tipo de analítica aplicable, corresponde ahora diseñar la arquitectura de datos que permitiría llevar la información desde las fuentes (sensores, sistemas de mantenimiento e informes técnicos) hasta los paneles de análisis y BI que apoyarían la decisión de programar el mantenimiento.

A continuación se presenta el diagrama del flujo completo, la justificación de las decisiones de lake/warehouse y batch/streaming, y una herramienta candidata para cada etapa principal.

2. Arquitectura del flujo de datos

El siguiente diagrama representa el recorrido de los datos desde las fuentes hasta el análisis y BI, pasando por ingesta, almacenamiento y procesamiento.





ALMACENAMIENTO

Data Lake → datos crudos de sensores e informes
Data Warehouse → datos limpios y modelados para BI
Herramienta candidata: Azure Data Lake + Synapse / Snowflake



PROCESAMIENTO

Limpieza de datos, detección de valores anormales,
entrenamiento e inferencia del modelo de riesgo de falla
Herramienta candidata: Python (pandas, scikit-learn) sobre Apache Spark



ANÁLISIS / BI

Paneles de riesgo por equipo, alertas e indicadores
para priorizar el mantenimiento
Herramienta candidata: Power BI

En resumen, el flujo sigue esta secuencia:

Fuentes → Ingesta → Almacenamiento (Lake + Warehouse) → Procesamiento → Análisis / BI

3. Data lake o data warehouse, batch o streaming

La arquitectura propuesta combina ambas alternativas en lugar de elegir una sola, ya que los distintos tipos de datos del proceso tienen necesidades diferentes de estructura y de frecuencia de actualización.



Decisión	Elección	Justificación breve
Data lake vs. data warehouse	Ambos (arquitectura combinada)	El lake guarda los datos crudos y variados de sensores e informes técnicos sin necesidad de definir su estructura de antemano; el warehouse guarda una versión limpia y modelada de esos datos, optimizada para que las herramientas de BI consulten rápido los indicadores de riesgo.
Batch vs. streaming	Ambos (arquitectura híbrida)	Los sensores IoT generan lecturas de forma continua y conviene procesarlas en streaming para detectar anomalías casi al momento; en cambio, el historial de fallas y mantenimientos del ERP/CMMS cambia con menor frecuencia y se puede cargar por lotes (batch), por ejemplo una vez al día.

Esta combinación es coherente con el diagnóstico de datos elaborado en la semana 4 del curso, donde se identificaron fuentes estructuradas (sensores, ERP/CMMS), semiestructuradas (eventos del sistema) y no estructuradas (informes técnicos): esa variedad es justamente lo que hace necesario un data lake como primer punto de llegada, y un data warehouse como capa posterior ya depurada para el consumo de BI.



4. Herramientas candidatas por etapa

Para cada etapa clave del flujo se propone una herramienta candidata, considerando que el caso ya identificó a Siemens Insights Hub como plataforma de monitoreo industrial.

Etapa	Herramienta candidata	Por qué
Ingesta	Siemens Insights Hub (o un bróker MQTT/Kafka)	Está pensado para recibir datos de sensores IoT industriales en tiempo real y ya se mencionó como plataforma de monitoreo en el diagnóstico previo del proceso; un bróker MQTT/Kafka es la alternativa estándar si se requiere mayor control sobre el flujo de streaming.
Procesamiento	Apache Spark (con Python: pandas y scikit-learn)	Permite procesar grandes volúmenes de datos de sensores en modo distribuido y es compatible con las bibliotecas de aprendizaje automático necesarias para construir el modelo de riesgo de falla.
BI / Visualización	Power BI	Facilita construir paneles con el nivel de riesgo por equipo y alertas, y se integra bien con almacenamiento en la nube tipo warehouse, lo que permite que los responsables de mantenimiento consulten la información sin necesidad de conocimientos técnicos.



No se incluye una herramienta específica para la etapa de almacenamiento porque la elección depende en gran medida del proveedor de nube que utilice la planta; sin embargo, opciones típicas para esta arquitectura combinada son Azure Data Lake Storage junto con Azure Synapse Analytics, o alternativas equivalentes como Snowflake o Google BigQuery.

5. Conclusión

El diseño de esta arquitectura muestra que el mantenimiento predictivo de Siemens no depende de una sola tecnología, sino de la combinación adecuada de un data lake para los datos crudos y variados, un data warehouse para los datos ya modelados, procesamiento en streaming para las señales de los sensores y procesamiento por lotes para la información histórica del ERP/CMMS. Esta arquitectura conecta directamente con el problema planteado en las semanas anteriores: llevar los datos generados por los equipos hasta un panel de BI que le permita a la planta anticipar fallas y programar el mantenimiento antes de que ocurra una parada no planificada.

6. Referencias

- [1] Siemens AG, "Insights Hub: plataforma de IoT industrial en la nube (anteriormente MindSphere)," Siemens Digital Industries Software, 2026. [Online]. Available: <https://www.siemens.com/en-us/products/insights-hub/>
- [2] Microsoft, "¿Qué es un data lake?," Microsoft Azure, 2026. [Online]. Available: <https://azure.microsoft.com/es-es/resources/cloud-computing-dictionary/what-is-a-data-lake>
- [3] IBM, "What is a data warehouse?," IBM Think, 2025. [Online]. Available: <https://www.ibm.com/think/topics/data-warehouse>





CORHUILA

CORPORACIÓN UNIVERSITARIA DEL HUILA
Vigilada Mineducación

INSTITUCIÓN DE EDUCACIÓN SUPERIOR SUJETA A INSPECCIÓN
Y VIGILANCIA POR EL MINISTERIO DE EDUCACIÓN NACIONAL - SNIES 2828

7.

[4] IBM, "Batch processing vs. stream processing," IBM Think, 2025. [Online]. Available: <https://www.ibm.com/think/topics/batch-processing-vs-stream-processing>

[5] Apache Software Foundation, "Apache Spark," 2026. [Online]. Available: <https://spark.apache.org>

[6] Microsoft, "Power BI documentation," Microsoft Learn, 2026. [Online]. Available: <https://learn.microsoft.com/power-bi/>

📍 Sede Quirinal: Calle 21 No. 6 - 01

📍 Sede Prado Alto: Calle 8 No. 32 - 49 PBX: (608) 8754220

📍 Sede Pitalito: Carrera 2 No. 1 - 27 - PBX: (608) 8360699

✉ Email: contacto@corhuila.edu.co - www.corhuila.edu.co

Personería Jurídica Res. Ministerio de Educación No. 21000 de Diciembre 22 de 1989
NIT. 800.107.584-2



CORPORACIÓN UNIVERSITARIA DEL HUILA - CORHUILA

"Diseño y prestación de servicios de docencia, investigación y extensión de programas de pregrado, aplicando todos los requisitos de las normas ISO implementadas en sus sedes Neiva y Pitalito"