



CORHUILA

CORPORACIÓN UNIVERSITARIA DEL HUILA
Vigilada Mineducación

INSTITUCIÓN DE EDUCACIÓN SUPERIOR SUJETA A INSPECCIÓN
Y VIGILANCIA POR EL MINISTERIO DE EDUCACIÓN NACIONAL - SNIES 2828

1.

Actividad Práctica — Semana 4

Tipos de analítica y ética en el mantenimiento predictivo de motores industriales

Cristhian Gaitán Guzmán

Facultad de Ingeniería, Corporación Universitaria del Huila

(CORHUILA), Ciencia de Datos (Cód. 69109), Pénsum 40D, Grupo 1

Docente: Jesús Ariel Gonzáles Bonilla

Septiembre de 2026

📍 Sede Quirinal: Calle 21 No. 6 - 01

📍 Sede Prado Alto: Calle 8 No. 32 - 49 PBX: (608) 8754220

📍 Sede Pitalito: Carrera 2 No. 1 - 27 - PBX: (608) 8360699

✉ Email: contacto@corhuila.edu.co - www.corhuila.edu.co

Personería Jurídica Res. Ministerio de Educación No. 21000 de Diciembre 22 de 1989

NIT. 800.107.584-2



CORPORACIÓN UNIVERSITARIA DEL HUILA - CORHUILA

"Diseño y prestación de servicios de docencia, investigación y extensión de programas de pregrado, aplicando todos los requisitos de las normas ISO implementadas en sus sedes Neiva y Pitalito"



Esta entrega continúa el caso de Siemens [1] trabajado en semanas anteriores: el mantenimiento predictivo [2] de motores y equipos industriales en una planta manufacturera. El objetivo de esta actividad es clasificar cuatro preguntas propias del caso según el tipo de analítica al que corresponden, definir qué enfoque de aprendizaje automático tendría sentido para la parte predictiva y prescriptiva, y reflexionar sobre un riesgo ético concreto asociado a este tipo de sistema.

1. Cuatro preguntas según el tipo de analítica

A continuación se formula una pregunta por cada tipo de analítica [3], tomando como referencia los datos de temperatura, vibración, consumo eléctrico y registros de mantenimiento de los motores de la planta.

Tipo de analítica	Pregunta sobre el caso Siemens	¿Qué responde?
Descriptiva	¿Cuántas fallas se registraron por motor durante el último trimestre y en qué franja horaria ocurrieron con más frecuencia?	¿Qué ocurrió?
Diagnóstica	¿Qué relación existe entre los picos de vibración y temperatura registrados antes de una falla y el tiempo transcurrido desde el último mantenimiento preventivo?	¿Por qué ocurrió?
Predictiva	Dado el comportamiento actual de temperatura, vibración y consumo eléctrico de un motor, ¿cuál es la probabilidad de que presente una falla en los próximos 15 días?	¿Qué puede ocurrir?



Tipo de analítica	Pregunta sobre el caso Siemens	¿Qué responde?
Prescriptiva	De los motores clasificados con riesgo alto de falla, ¿cuál debería intervenir primero y qué tipo de mantenimiento debería programarse para minimizar el impacto en la producción?	¿Qué deberíamos hacer?

2. Enfoque de aprendizaje automático: supervisado vs. no supervisado

La analítica predictiva y la prescriptiva no requieren necesariamente el mismo tipo de modelo. La tabla siguiente indica el enfoque de ML que se usaría en cada caso y por qué.

Tipo de analítica	Enfoque de ML	Justificación
Predictiva	Supervisado	El historial de mantenimiento y de fallas permite construir un conjunto de datos etiquetado: cada registro de sensor puede asociarse a si el motor falló o no en un periodo posterior. Con esa etiqueta (falla / no falla), un modelo de clasificación supervisada [4] puede aprender a estimar la probabilidad de falla futura a partir de variables como temperatura, vibración y consumo eléctrico.
Prescriptiva	Combinación: reglas de decisión sobre la salida del modelo supervisado, apoyadas en no supervisado para priorizar	La prescriptiva no necesita un modelo propio de aprendizaje: toma la probabilidad de falla que entrega el modelo predictivo (supervisado) y la traduce en una acción mediante reglas de negocio (por ejemplo, umbrales de riesgo). Sin embargo, técnicas no supervisadas de agrupamiento (clustering) pueden ser útiles antes de eso, para agrupar motores con patrones de comportamiento similares y así priorizar de forma consistente cuáles intervenir primero, incluso cuando no existan etiquetas claras de falla para todos los equipos.

En resumen: el núcleo predictivo del sistema se apoya en aprendizaje supervisado porque existe una variable objetivo clara (falló / no falló) derivada del historial de mantenimiento. El componente



prescriptivo, en cambio, se apoya principalmente en reglas de decisión sobre esa salida, y puede beneficiarse de técnicas no supervisadas de agrupamiento cuando se quiere priorizar equipos sin depender de etiquetas históricas completas para todos ellos.

3. Riesgo ético o de sesgo y su mitigación

3.1 Riesgo identificado

Un riesgo real en este tipo de sistema es el sesgo por desbalance de datos entre equipos [5]. Si el modelo se entrena principalmente con el historial de los motores más antiguos o de las líneas de producción con más sensores instalados, aprenderá mejor a predecir fallas en esos equipos que en motores más nuevos, en líneas con menos instrumentación o en sedes distintas de la planta. El resultado sería un sistema que subestima el riesgo real de fallas en equipos "menos vistos" por el modelo, lo cual podría llevar a que esos motores no reciban mantenimiento oportuno mientras se prioriza a los que ya están sobre-representados en los datos históricos.

Existe también un riesgo relacionado: si las decisiones de mantenimiento se automatizan por completo a partir del modelo, un error de predicción (falso negativo) podría traducirse en una parada no planificada que además afecta la seguridad del personal que opera el equipo, no solo la producción.



3.2 Mitigación propuesta

- Revisar que el conjunto de entrenamiento incluya de forma proporcional datos de todos los equipos, líneas y sedes, y no solo de los motores con más sensores o más años en operación.
- Definir un umbral de confianza mínimo por debajo del cual el modelo no decide solo: la recomendación pasa a un técnico de mantenimiento para validación antes de descartar una alerta.
- Medir el desempeño del modelo por subgrupo de equipos (por ejemplo, por línea de producción o antigüedad), no solo con una métrica global, para detectar si el sistema falla sistemáticamente más en algún subgrupo [6].
- Mantener trazabilidad de cada recomendación de mantenimiento generada por el modelo, de modo que se pueda auditar después por qué se priorizó o no un equipo.

4. Conclusión

Clasificar el caso de Siemens en los cuatro tipos de analítica permite ver que no todas las preguntas necesitan el mismo tipo de modelo: la descriptiva y la diagnóstica se resuelven con análisis de datos históricos, mientras que la predictiva requiere aprendizaje supervisado apoyado en el historial de fallas, y la prescriptiva traduce esa predicción en una acción concreta de mantenimiento. Al mismo tiempo, un sistema de este tipo no está exento de riesgos: el desbalance de datos entre equipos puede generar un sesgo que perjudique justamente a los motores menos representados en el historial, por lo que la mitigación debe formar parte del diseño del sistema desde el principio y no ser un ajuste posterior.



5. Referencias

- [1] Siemens AG, "Insights Hub: plataforma de IoT industrial en la nube (anteriormente MindSphere)," Siemens Digital Industries Software, 2026. [Online]. Available: <https://www.siemens.com/en-us/products/insights-hub/>
- [2] IBM, "¿Qué es el mantenimiento predictivo?," IBM Think, 2026. [Online]. Available: <https://www.ibm.com/think/topics/predictive-maintenance>
- [3] IBM, "What Is Diagnostic Analytics?," IBM Think, 2025. [Online]. Available: <https://www.ibm.com/think/topics/diagnostic-analytics>
- [4] IBM, "What Is Supervised Learning?," IBM Think, 2026. [Online]. Available: <https://www.ibm.com/think/topics/supervised-learning>
- [5] IBM, "What is data quality?," IBM Think, 2025. [Online]. Available: <https://www.ibm.com/think/topics/data-quality>
- [6] IBM, "What Is AI Bias?," IBM Think, 2025. [Online]. Available: <https://www.ibm.com/think/topics/ai-bias>